

2. Projekt

Quasi-Newton-Verfahren & Gauß-Newton-Verfahren

im Fach

Numerische Optimierung

Juni 2020

Maximilian Gaul

Aufgabe 1

Siehe Programmcode in Project2.m.

Aufgabe 2

Für A^0 wählt man im BFGS-Verfahren üblicherweise die Einheitsmatrix, d.h. für den Induktionsanfang gilt:

$$A^0 = I$$

Wenn man das nun in die Formel für die zwei Rang-1-Modifikationen und in die BFGS-Update-Formel einsetzt erhält man den Ansatz (für $B = A^{-1} = I$):

$$\left(I + \frac{ss^T - ys^T + ss^T - sy^T}{y^T s} - \frac{s^T y s s^T - y^T y s s^T}{(y^T)^2 s^2} \right) \cdot \left(I - \frac{ss^T}{s^T s} + \frac{yy^T}{y^T s} \right)$$

Der Übersicht halber teile ich die einzelnen Produkte auf und füge sie nach dem Kürzen am Ende wieder zusammen. Es ist zu beachten, dass $y^T s = s^T y$. Skalare Werte werden gekürzt.

$$I \cdot I = I$$

$$I \cdot \left(-\frac{ss^T}{s^T s} \right) = -\frac{ss^T}{s^T s}$$

$$I \cdot \left(\frac{yy^T}{y^T s} \right) = \frac{yy^T}{y^T s}$$

$$\left(\frac{ss^T - ys^T + ss^T - sy^T}{y^T s} \right) \cdot I = \frac{ss^T}{y^T s} - \frac{ys^T}{y^T s} + \frac{ss^T}{y^T s} - \frac{sy^T}{y^T s}$$

$$\left(\frac{ss^T - ys^T + ss^T - sy^T}{y^T s} \right) \cdot \left(-\frac{ss^T}{s^T s} \right) = -\frac{ss^T ss^T - ys^T ss^T + ss^T ss^T - sy^T ss^T}{y^T ss^T s}$$

$$= -\frac{ss^T ss^T}{y^T ss^T s} + \frac{ys^T ss^T}{y^T ss^T s} - \frac{ss^T ss^T}{y^T ss^T s} + \frac{sy^T ss^T}{y^T ss^T s} = -\frac{ss^T}{y^T s} + \frac{ys^T}{y^T s} - \frac{ss^T}{y^T s} + \frac{ss^T}{s^T s}$$

$$\left(\frac{ss^T - ys^T + ss^T - sy^T}{y^T s} \right) \cdot \left(\frac{yy^T}{y^T s} \right) = \frac{ss^T y - ys^T yy^T + ss^T yy^T - sy^T yy^T}{(y^T s)^2}$$

$$= \frac{ss^T yy^T}{(y^T s)^2} - \frac{ys^T yy^T}{(y^T s)^2} + \frac{ss^T yy^T}{(y^T s)^2} - \frac{sy^T yy^T}{(y^T s)^2} = \frac{sy^T}{y^T s} - \frac{yy^T}{y^T s} + \frac{sy^T}{y^T s} - \frac{sy^T yy^T}{(y^T s)^2}$$

$$\begin{aligned}
\left(-\frac{s^T y s s^T - y^T y s s^T}{(y^T s)^2} \right) \cdot I &= -\frac{\textcolor{red}{s}^T y s s^T}{(\textcolor{red}{y}^T \textcolor{red}{s})^2} + \frac{y^T y s s^T}{(y^T s)^2} = -\frac{s s^T}{y^T s} + \frac{y^T y s s^T}{(y^T s)^2} \\
\left(-\frac{s^T y s s^T - y^T y s s^T}{(y^T s)^2} \right) \cdot \left(-\frac{s s^T}{s^T s} \right) &= \frac{s^T y s s^T s s^T - y^T y s s^T s s^T}{(y^T s)^2 s^T s} \\
&= \frac{\textcolor{red}{s}^T y s \textcolor{blue}{s}^T s s^T}{(\textcolor{red}{y}^T \textcolor{red}{s})^2 \textcolor{blue}{s}^T \textcolor{blue}{s}} - \frac{y^T y s \textcolor{blue}{s}^T s s^T}{(y^T s)^2 \textcolor{blue}{s}^T \textcolor{blue}{s}} = \frac{s s^T}{y^T s} - \frac{y^T y s s^T}{(y^T s)^2} \\
\left(-\frac{s^T y s s^T - y^T y s s^T}{(y^T s)^2} \right) \cdot \left(\frac{y y^T}{y^T s} \right) &= -\frac{s^T y s s^T y y^T + y^T y s s^T y y^T}{(y^T s)^3} \\
&= -\frac{\textcolor{red}{s}^T y s \textcolor{red}{s}^T y y^T}{(\textcolor{red}{y}^T \textcolor{red}{s})^3} + \frac{y^T y s \textcolor{red}{s}^T y y^T}{(\textcolor{red}{y}^T \textcolor{red}{s})^3} = -\frac{s y^T}{y^T s} + \frac{y^T y s y^T}{(y^T s)^2}
\end{aligned}$$

Zusammenfassen:

$$\begin{aligned}
I - \frac{\textcolor{red}{s} \textcolor{red}{s}^T}{\textcolor{red}{s}^T \textcolor{red}{s}} + \frac{\textcolor{blue}{y} \textcolor{blue}{y}^T}{\textcolor{blue}{y}^T \textcolor{blue}{s}} + \frac{\textcolor{green}{s} \textcolor{green}{s}^T}{\textcolor{green}{y}^T \textcolor{green}{s}} - \frac{\textcolor{orange}{y} \textcolor{orange}{s}^T}{\textcolor{orange}{y}^T \textcolor{orange}{s}} + \frac{s s^T}{y^T s} - \frac{\textcolor{red}{s} \textcolor{red}{y}^T}{\textcolor{red}{y}^T \textcolor{red}{s}} - \frac{\textcolor{green}{s} \textcolor{green}{s}^T}{\textcolor{green}{y}^T \textcolor{green}{s}} + \frac{\textcolor{orange}{y} \textcolor{orange}{s}^T}{\textcolor{orange}{y}^T \textcolor{orange}{s}} - \frac{s s^T}{y^T s} + \frac{\textcolor{red}{s} \textcolor{red}{s}^T}{\textcolor{red}{s}^T \textcolor{red}{s}} + \frac{\textcolor{red}{s} \textcolor{red}{y}^T}{\textcolor{red}{y}^T \textcolor{red}{s}} - \frac{\textcolor{blue}{y} \textcolor{blue}{y}^T}{\textcolor{blue}{y}^T \textcolor{blue}{s}} + \frac{\textcolor{blue}{s} \textcolor{blue}{y}^T}{\textcolor{blue}{y}^T \textcolor{blue}{s}} \\
- \frac{\textcolor{red}{s} \textcolor{red}{y}^T y y^T}{(y^T s)^2} - \frac{s s^T}{y^T s} + \frac{y^T y s s^T}{(y^T s)^2} + \frac{s s^T}{y^T s} - \frac{y^T y s s^T}{(y^T s)^2} - \frac{\textcolor{blue}{s} \textcolor{blue}{y}^T}{\textcolor{blue}{y}^T \textcolor{blue}{s}} + \frac{y^T y s y^T}{(y^T s)^2} = I
\end{aligned}$$

Im Induktionsschritt geht man von $k = 0$ auf allgemeines k , dann erhält man folgenden Ansatz (für $B = A^{-1}$, k wurde zur besseren Übersichtlichkeit weggelassen):

$$\left(A^{-1} + \frac{(s - A^{-1}y)s^T + s(s - A^{-1}y)^T}{y^T s} - \frac{(s - A^{-1}y)^T y s s^T}{(y^T s)^2} \right) \cdot \left(A - \frac{As(As)^T}{s^T As} + \frac{y y^T}{y^T s} \right)$$

Die einzelnen Produkte werden wieder aufgeteilt:

$$(A^{-1}) \cdot (A) = I$$

$$(A^{-1}) \cdot \left(-\frac{As(As)^T}{s^T As} \right) = -\frac{s(As)^T}{s^T As} = -\frac{s s^T A}{s^T As}$$

$$(A^{-1}) \cdot \left(\frac{y y^T}{y^T s} \right) = \frac{A^{-1} y y^T}{y^T s}$$

$$\left(\frac{(s - A^{-1}y)s^T + s(s - A^{-1}y)^T}{y^T s} \right) \cdot (A) = \frac{s s^T A - A^{-1} y s^T A + s s^T A - s y^T A^{-1} A}{y^T s}$$

$$= \frac{s s^T A}{y^T s} - \frac{A^{-1} y s^T A}{y^T s} + \frac{s s^T A}{y^T s} - \frac{s y^T}{y^T s}$$

$$\begin{aligned}
& \left(\frac{(s - A^{-1}y)s^T + s(s - A^{-1}y)^T}{y^T s} \right) \cdot \left(-\frac{As(As)^T}{s^T As} \right) = -\frac{ss^T As s^T A - A^{-1}ys^T As s^T A + s(s^T - y^T A^{-1})As s^T A}{y^T s s^T As} \\
& = -\frac{ss^T As s^T A}{y^T s s^T As} + \frac{A^{-1}ys^T As s^T A}{y^T s s^T As} - \frac{ss^T As s^T A}{y^T s s^T As} + \frac{sy^T s s^T A}{y^T s s^T As} \\
& = -\frac{ss^T A}{y^T s} + \frac{A^{-1}ys^T A}{y^T s} - \frac{ss^T A}{y^T s} + \frac{ss^T A}{s^T As}
\end{aligned}$$

$$\begin{aligned}
& \left(\frac{(s - A^{-1}y)s^T + s(s - A^{-1}y)^T}{y^T s} \right) \cdot \left(\frac{yy^T}{y^T s} \right) = \frac{ss^T yy^T - A^{-1}ys^T yy^T + ss^T yy^T - sy^T A^{-1}yy^T}{(y^T s)^2} \\
& = \frac{ss^T yy^T}{(y^T s)^2} - \frac{A^{-1}ys^T yy^T}{(y^T s)^2} + \frac{ss^T yy^T}{(y^T s)^2} - \frac{sy^T A^{-1}yy^T}{(y^T s)^2} \\
& = \frac{sy^T}{y^T s} - \frac{A^{-1}yy^T}{y^T s} + \frac{sy^T}{y^T s} - \frac{sy^T A^{-1}yy^T}{(y^T s)^2} \\
& \left(-\frac{(s - A^{-1}y)^T y s s^T}{(y^T s)^2} \right) \cdot (A) = -\frac{s^T y s s^T A - y^T A^{-1}y s s^T A}{(y^T s)^2} \\
& = -\frac{s^T y s s^T A}{(y^T s)^2} + \frac{y^T A^{-1}y s s^T A}{(y^T s)^2} = -\frac{ss^T A}{y^T s} + \frac{y^T A^{-1}y s s^T A}{(y^T s)^2}
\end{aligned}$$

$$\begin{aligned}
& \left(-\frac{(s - A^{-1}y)^T y s s^T}{(y^T s)^2} \right) \cdot \left(-\frac{As(As)^T}{s^T As} \right) = \frac{s^T y s s^T As s^T A - y^T A^{-1}y s s^T As s^T A}{(y^T s)^2 s^T As} \\
& = \frac{s^T y s s^T As s^T A}{(y^T s)^2 s^T As} - \frac{y^T A^{-1}y s s^T As s^T A}{(y^T s)^2 s^T As} = \frac{ss^T A}{y^T s} - \frac{y^T A^{-1}y s s^T A}{(y^T s)^2}
\end{aligned}$$

$$\begin{aligned}
& \left(-\frac{(s - A^{-1}y)^T y s s^T}{(y^T s)^2} \right) \cdot \left(\frac{yy^T}{y^T s} \right) = -\frac{s^T y s s^T yy^T - y^T A^{-1}y s s^T yy^T}{(y^T s)^3} \\
& = -\frac{s^T y s s^T yy^T}{(y^T s)^3} + \frac{y^T A^{-1}y s s^T yy^T}{(y^T s)^3} = -\frac{sy^T}{y^T s} + \frac{y^T A^{-1}y sy^T}{(y^T s)^2}
\end{aligned}$$

Zusammenfassen

$$\begin{aligned}
I - \frac{ss^T A}{s^T As} + \frac{A^{-1}yy^T}{y^T s} + \frac{ss^T A}{y^T s} - \frac{A^{-1}ys^T A}{y^T s} + \frac{ss^T A}{y^T s} - \frac{sy^T}{y^T s} - \frac{ss^T A}{y^T s} + \frac{A^{-1}ys^T A}{y^T s} - \frac{ss^T A}{y^T s} \\
+ \frac{ss^T A}{s^T As} + \frac{sy^T}{y^T s} - \frac{A^{-1}yy^T}{y^T s} + \frac{sy^T}{y^T s} - \frac{sy^T A^{-1}yy^T}{(y^T s)^2} - \frac{ss^T A}{y^T s} + \frac{y^T A^{-1}y s s^T A}{(y^T s)^2}
\end{aligned}$$

$$+\frac{ss^T A}{y^T s} - \frac{y^T A^{-1} y s s^T A}{(y^T s)^2} - \frac{sy^T}{y^T s} + \frac{y^T A^{-1} y s y^T}{(y^T s)^2} = I$$

Da $y^T A^{-1} y$ ein Skalar ist, kann es beliebig verschoben werden, d.h. $sy^T A^{-1} y y^T = y^T A^{-1} y s y^T$.

Für $k + 1$ ändert sich an der oben gezeigten Rechnung nichts. Jeder Vektor bzw. jede Matrix erhält dann einfach nur den Index $k + 1$.

Aufgabe 3

Wenn die Suchrichtung des BFGS Verfahrens:

$$d = -B \cdot \nabla f(x)$$

keine Abstiegsrichtung ist, d.h. die Bedingung:

$$\nabla f(x)^T \cdot d < 0$$

nicht erfüllt ist, muss das Verfahren 'resettet' werden. In diesem Fall bietet es sich an, die Suchrichtung auf den negativen Gradienten zu setzen:

$$d = -\nabla f(x)$$

Da nun die Abstiegsrichtung nicht mehr zur approximated Inversen der Hesse-Matrix B passt, muss diese ebenfalls für den nächsten Schritt neu bestimmt werden (bzw. das nächste Update erfolgt dann mit dieser Matrix).

Hierzu bieten sich verschiedene Möglichkeiten an:

- Wie beim Start des BFGS-Verfahrens $B = I$ setzen
 - Hierbei geht jeglicher berechnete Fortschritt verloren, es handelt sich um einen recht naiven Ansatz
- Die Hesse-Matrix einmalig aus Differenzenquotienten des Gradienten bestimmen und anschließend invertieren
 - Hoher Rechenaufwand von $\mathcal{O}(n^2)$ für die Hesse-Matrix und nochmal $\mathcal{O}(n^3)$ für das Invertieren
 - Problem wenn die Hesse-Matrix nicht invertierbar ist bzw. aufgrund von Auslöschung oder anderen numerischen Fehlern die Inverse schlecht konditioniert ist
 - Bisher berechneter Fortschritt geht ebenfalls verloren aber die Approximation der Hesse-Matrix ist sehr genau
- Man könnte, wie in den Vorlesungsfolien beschrieben, $\frac{y^T s}{y^T y} \cdot I_n$ als positiv-definitve Matrix verwenden

- Der Fortschritt geht zwar ähnlich wie bei $B = I$ weitestgehend verloren, allerdings überträgt man noch Informationen von y und s auf den nächsten Schritt, erscheint also sinnvoller als die erste Variante

Um herauszufinden, welche dieser Methoden am besten geeignet ist (d.h. die richtige Lösung in der kürzesten Zeit findet), wird die Laufzeit des inversen BFGS-Verfahrens bestimmt. Startwerte:

- N-dim. Rosenbrock-Funktion: $\begin{bmatrix} -1 \\ \vdots \\ -1 \end{bmatrix}$
- Himmelblau-Funktion: $\begin{bmatrix} 0 \\ -1 \end{bmatrix}$
- Bazaraa-Shetty: $\begin{bmatrix} 0 \\ -1 \end{bmatrix}$




Abbildung 1: Vergleich der Rechenzeit für eine Genauigkeit von 10^{-8} gemittelt über 100 Durchläufe (Intel Core i3-7100U, 8GB RAM, Windows 10 64-Bit)

Alle drei Funktionen profitieren von $B = \frac{y^T s}{y^T y} \cdot I$, daher habe ich diesen Weg in meiner Implementierung gewählt.

Aufgabe 4

Auswertungen der Himmelblau-Funktion

$$f(x_1, x_2) = (x_1^2 + x_2 - 11)^2 + (x_1 + x_2^2 - 7)^2$$

Mit Gradient:

$$\nabla f(x_1, x_2) = \begin{bmatrix} 2 \cdot (x_1^2 + x_2 - 11) \cdot 2x_1 + 2 \cdot (x_1 + x_2^2 - 7) \\ 2 \cdot (x_1^2 + x_2 - 11) + 2 \cdot (x_1 + x_2^2 - 7) \cdot 2x_2 \end{bmatrix}$$

Schritt	\mathbf{x}	$f(x)$
1	$[0.00, -1.00]^T$	180
2	$[4.50, -1.00]^T$	70.31
3	$[2.54, -1.86]^T$	41.79
4	$[2.68, -2.26]^T$	37.84
5	$[4.16, -1.94]^T$	20.24
\vdots	\vdots	\vdots
13	$[3.58, -1.85]^T$	$6.37 \cdot 10^{-20}$

Abbildung 2: Verlauf von InverseBFGS für f bei einer Genauigkeit von 10^{-8} . Man erkennt gut die superlineare Konvergenz.

Schritt	\mathbf{x}	$f(x)$
1	$[0.00, -1.00]^T$	180
2	keine Info	06.38
3	keine Info	05.91
4	keine Info	00.26
5	keine Info	0.00
\vdots	\vdots	\vdots
9	$[3.58, -1.85]^T$	$7.05 \cdot 10^{-13}$

Abbildung 3: Verlauf von fminunc für f bei einer Genauigkeit von 10^{-8} mit Einstellungen HessUpdate = 'bfgs' und Display = 'iter-detailed'.

Die Rosenbrock-Funktion ist in Projekt2.m als f_rosen_mult definiert. Beispielsweise für $N = 3$

$$g(x_1, x_2, x_3) = \sum_{i=1}^2 (1 - x_i)^2 + 100 \cdot (x_{i+1} - x_i^2)^2$$

=

$$(1 - x_1)^2 + 100 \cdot (x_2 - x_1^2)^2 + (1 - x_2)^2 + 100 \cdot (x_3 - x_2^2)^2$$

habe ich den Gradienten bestimmt:

$$\nabla g_3 = \begin{bmatrix} -2 \cdot (1 - x_1) + 200 \cdot (x_2 - x_1^2) \cdot (-2x_1) \\ 200 \cdot (x_2 - x_1^2) - 2 \cdot (1 - x_2) + 200 \cdot (x_3 - x_2^2) \cdot (-2x_2) \\ 200 \cdot (x_3 - x_2^2) \end{bmatrix}$$

Man erkennt eine Regel: Der Gradient besteht aus drei Teilen. Der erste Eintrag im Gradienten ist:

$$-2 \cdot (1 - x_1) + 200 \cdot (x_2 - x_1^2) \cdot (-2x_1)$$

Alle weiteren Einträge (bis auf den letzten an Position $N - 1$) sind:

$$200 \cdot (x_i - x_{i-1}^2) - 2 \cdot (1 - x_i) + 200 \cdot (x_{i+1} - x_i^2) \cdot (-2x_i)$$

Der letzte Eintrag ist:

$$200 \cdot (x_N - x_{N-1}^2)$$

Die Ableitung ist in Projekt2.m in der Funktion `f_rosen_mult_deriv_func` definiert.

Schritt	\mathbf{x}	$f(x)$
1	$[-1.0, -1.0, \dots, -1.0]^T$	3636.00
2	$[0.57, 1.35, \dots, -0.22]^T$	682.94
3	$[0.94, 1.25, \dots, 0.20]^T$	508.69
4	$[1.33, 1.29, \dots, 0.52]^T$	419.10
5	$[1.45, 1.40, \dots, 1.43]^T$	379.44
\vdots	\vdots	\vdots
49	$[1.00, 1.00, \dots, 1.00]^T$	$2.2 \cdot 10^{-21}$

Abbildung 4: Verlauf von `InverseBFGS` für die 10-dim. Rosenbrock-Funktion bei einer Genauigkeit von 10^{-8} .




Abbildung 5: Rechenzeit der N-dimensionalen Rosenbrock-Funktion mit Startwert $[-1, \dots, -1]^T$ für eine Genauigkeit von 10^{-8} gemittelt über 100 Durchläufe von InverseBFGS (Intel Core i3-7100U, 8GB RAM, Windows 10 64-Bit)

Schritt	\mathbf{x}	$f(\mathbf{x})$
1	$[-1.0, -1.0, \dots, -1.0]^T$	3636.00
2	keine Info	55.59
3	keine Info	41.02
4	keine Info	9.56
5	keine Info	9.49
\vdots	\vdots	\vdots
79	$[1.00, 1.00, \dots, 1.00]^T$	$6.07 \cdot 10^{-11}$

Abbildung 6: Verlauf von `fminunc` für die 10-dim. Rosenbrock-Funktion bei einer Genauigkeit von 10^{-8} mit Einstellungen `HessUpdate = 'bfgs'` und `Display = 'iter-detailed'`.




Abbildung 7: Rechenzeit der N-dimensionalen Rosenbrock-Funktion mit Startwert $[-1, \dots, -1]^T$ für eine Genauigkeit von 10^{-8} gemittelt über 100 Durchläufe von `fminunc` mit `HessUpdate = 'bfgs'` (Intel Core i3-7100U, 8GB RAM, Windows 10 64-Bit)

Man erkennt, dass mit höheren Dimensionen die Rechenzeit für beide Verfahren drastisch zunimmt und `fminunc` deutlich früher 3s pro Durchlauf benötigt.

Verfahren	Dimensionen	Dauer	Genauigkeit	Anmerkung
InverseBFGS	750	14.05s	10^{-8}	Zielfunktionswert: 3.98, die ersten 8 Werte bei 0.9967
InverseBFGS	850	22.07s	10^{-8}	Zielfunktionswert: $1.4 \cdot 10^{-20}$, keine Werte $\neq 1$
InverseBFGS	925	24.66s	10^{-8}	Zielfunktionswert: $5.8 \cdot 10^{-21}$, keine Werte $\neq 1$
fminunc	750	127.95s	10^{-8}	Zielfunktionswert: $1.8 \cdot 10^{-10}$, keine Werte $\neq 1$
fminunc	850	152.15s	10^{-8}	Zielfunktionswert: $1.7 \cdot 10^{-10}$, keine Werte $\neq 1$
fminunc	925	212.60s	10^{-8}	Zielfunktionswert: $1.9 \cdot 10^{-10}$, keine Werte $\neq 1$

Abbildung 8: Unterschiede zwischen beiden Verfahren bei der Berechnung der N-dimensionalen Rosenbrock-Funktion bei hohen Dimensionen

Möglichkeiten um ein höheres N zu erreichen:

- Nach den Regeln der Analysis lässt sich eine Summe aufteilen in zwei Summen:

$$\begin{aligned}
 & \sum_{i=1}^{N-1} (1 - x_i)^2 + 100 \cdot (x_{i+1} - x_i^2)^2 \\
 & = \\
 & \sum_{i=1}^a (1 - x_i)^2 + 100 \cdot (x_{i+1} - x_i^2)^2 + \sum_{i=a+1}^{N-1} (1 - x_i)^2 + 100 \cdot (x_{i+1} - x_i^2)^2
 \end{aligned}$$

Die Berechnung des Minimums dieser zwei Summen kann auf z.B. zwei Threads aufgeteilt und am Ende wieder zusammengefügt werden. Bei ungeradem N muss man sich entscheiden wie die Summe aufgeteilt wird, ein Thread bearbeitet dann eine Dimension mehr als der andere. Bei besonders großem N können auch diese beiden Summen wiederum aufgeteilt und somit auf noch mehr Threads verteilt werden.

- Verwenden von sparse-Matrizen und Vektoren durch die sich die Rechenzeit unter Umständen reduzieren kann. Sparse-Datenstrukturen verwenden eine spezielle Repräsentation der Werte in denen Einträge mit 0 effizienter gespeichert werden. Aufgründessen beschleunigt sich die Berechnung von Matrix-Vektor-Produkten (die beim BFGS-Verfahren sehr oft verwendet werden)
- Gegebenfalls genauere Untersuchungen über Kondition und Stabilität der Operationen bzw. wie diese verbessert werden können. Durch Auslöschung in der Update-Formel könnte es unter Umständen zu fehlerhaften Richtungsvektoren kommen die sich bei besonders großen Problemen potenzieren und somit die Konvergenz verlangsamen.

Aufgabe 5

Die gegebene symmetrische Rang-1 Formel erhält man durch eine Rang-1 Modifikation

$$A^{k+1} = A^k + c \cdot u \cdot v^T$$

mit $c = \frac{1}{u^T s}$, $u = y - A^k s$ und $v = c \cdot u$.

Diese kann man nun in die Sherman-Morrison-Woodbury-Formel einsetzen und erhält somit den Ansatz:

$$A^{-1} - \frac{A^{-1}(y - As) \left(\frac{y - As}{(y - As)^T s} \right)^T A^{-1}}{1 + \left(\frac{y - As}{(y - As)^T s} \right)^T A^{-1}(y - As)}$$

Wenn man das T in den Bruch im Nenner und Zähler einfließen lässt, erhält man diesen Doppelbruch:

$$A^{-1} - \frac{\frac{A^{-1}(y - As)(y - As)^T A^{-1}}{((y - As)^T s)^T}}{1 + \frac{(y - As)^T A^{-1}(y - As)}{((y - As)^T s)^T}}$$

Nun den Zähler vom Zähler ausmultipliziert:

$$A^{-1} - \frac{\frac{(A^{-1}y - A^{-1}As)(y^T - (As)^T)A^{-1}}{((y - As)^T s)^T}}{1 + \frac{(y - As)^T A^{-1}(y - As)}{((y - As)^T s)^T}}$$

$$A^{-1} - \frac{\frac{(A^{-1}y - s)(y^T - s^T A)A^{-1}}{((y - As)^T s)^T}}{1 + \frac{(y - As)^T A^{-1}(y - As)}{((y - As)^T s)^T}}$$

$$A^{-1} - \frac{\frac{(A^{-1}y - s)(y^T A^{-1} - s^T A A^{-1})}{((y - As)^T s)^T}}{1 + \frac{(y - As)^T A^{-1}(y - As)}{((y - As)^T s)^T}}$$

$$A^{-1} - \frac{\frac{(A^{-1}y - s)(y^T A^{-1} - s^T)}{((y - As)^T s)^T}}{1 + \frac{(y - As)^T A^{-1}(y - As)}{((y - As)^T s)^T}}$$

Ebenfalls den Zähler im Nenner ausmultiplizieren:

$$A^{-1} - \frac{\frac{(A^{-1}y - s)(y^T A^{-1} - s^T)}{((y - As)^T s)^T}}{1 + \frac{(y^T - (As)^T)A^{-1}(y - As)}{((y - As)^T s)^T}}$$

$$A^{-1} - \frac{\frac{(A^{-1}y - s)(y^T A^{-1} - s^T)}{((y - As)^T s)^T}}{1 + \frac{(y^T - s^T A)A^{-1}(y - As)}{((y - As)^T s)^T}}$$

$$\begin{aligned}
A^{-1} &= \frac{\frac{(A^{-1}y-s)(y^T A^{-1}-s^T)}{((y-As)^T s)^T}}{1 + \frac{(y^T A^{-1}-s^T)(y-As)}{((y-As)^T s)^T}} \\
A^{-1} &= \frac{\frac{(A^{-1}y-s)(y^T A^{-1}-s^T)}{((y-As)^T s)^T}}{1 + \frac{y^T A^{-1}y - y^T A^{-1}As - s^T y + s^T As}{((y-As)^T s)^T}} \\
A^{-1} &= \frac{\frac{(A^{-1}y-s)(y^T A^{-1}-s^T)}{((y-As)^T s)^T}}{1 + \frac{y^T A^{-1}y - y^T s - s^T y + s^T As}{((y-As)^T s)^T}} \\
A^{-1} &= \frac{\frac{(A^{-1}y-s)(y^T A^{-1}-s^T)}{((y-As)^T s)^T}}{1 + \frac{y^T (A^{-1}y-s) - s^T (y-As)}{((y-As)^T s)^T}}
\end{aligned}$$

Die 1 im Nenner erweitern:

$$A^{-1} = \frac{\frac{(A^{-1}y-s)(y^T A^{-1}-s^T)}{((y-As)^T s)^T}}{\frac{((y-As)^T s)^T}{((y-As)^T s)^T} + \frac{y^T (A^{-1}y-s) - s^T (y-As)}{((y-As)^T s)^T}}$$

mit dem zweiten Term verbinden:

$$A^{-1} = \frac{\frac{(A^{-1}y-s)(y^T A^{-1}-s^T)}{((y-As)^T s)^T}}{\frac{((y-As)^T s)^T + y^T (A^{-1}y-s) - s^T (y-As)}{((y-As)^T s)^T}}$$

ausmultiplizieren:

$$\begin{aligned}
A^{-1} &= \frac{\frac{(A^{-1}y-s)(y^T A^{-1}-s^T)}{((y-As)^T s)^T}}{\frac{s^T (y-As) + y^T A^{-1}y - y^T s - s^T y + s^T As}{((y-As)^T s)^T}} \\
A^{-1} &= \frac{\frac{(A^{-1}y-s)(y^T A^{-1}-s^T)}{((y-As)^T s)^T}}{\frac{s^T y - s^T As + y^T A^{-1}y - y^T s - s^T y + s^T As}{((y-As)^T s)^T}}
\end{aligned}$$

und kürzen:

$$\begin{aligned}
A^{-1} &= \frac{\frac{(A^{-1}y-s)(y^T A^{-1}-s^T)}{((y-As)^T s)^T}}{\frac{y^T A^{-1}y - y^T s}{((y-As)^T s)^T}} \\
A^{-1} &= \frac{\frac{(A^{-1}y-s)(y^T A^{-1}-s^T)}{((y-As)^T s)^T}}{\frac{y^T (A^{-1}y-s)}{((y-As)^T s)^T}}
\end{aligned}$$

Den Doppelbruch auflösen:

$$A^{-1} = \frac{(A^{-1}y - s)(y^T A^{-1} - s^T)}{((y - As)^T s)^T} \cdot \frac{((y - As)^T s)^T}{y^T (A^{-1}y - s)}$$

Wenn man sich die nun gegenüberstehenden Terme ansieht:

$$((y - As)^T s)^T$$

erkennt man, dass es sich hierbei um eine Zahl handelt (beispielhaft für ein 2×2 -System):

$$\begin{aligned} & \left(\left(\begin{bmatrix} 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 2 & 3 \\ 3 & -1 \end{bmatrix} \cdot \begin{bmatrix} 3 \\ 2 \end{bmatrix} \right)^T \cdot \begin{bmatrix} 3 \\ 2 \end{bmatrix} \right)^T \\ & \left(\left(\begin{bmatrix} 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 12 \\ 7 \end{bmatrix} \right)^T \cdot \begin{bmatrix} 3 \\ 2 \end{bmatrix} \right)^T \\ & \left(\left(\begin{bmatrix} -11 \\ -6 \end{bmatrix} \right)^T \cdot \begin{bmatrix} 3 \\ 2 \end{bmatrix} \right)^T \\ & \left(\begin{bmatrix} -11 & -6 \end{bmatrix} \cdot \begin{bmatrix} 3 \\ 2 \end{bmatrix} \right)^T \\ & (-45)^T = -45 \end{aligned}$$

D.h. man darf den Doppelbruch kürzen, dann erhält man:

$$A^{-1} = \frac{(A^{-1}y - s)(y^T A^{-1} - s^T)}{y^T (A^{-1}y - s)}$$

Um den Ausdruck noch schöner zu machen, kann man jeweils ein Minus aus den zwei Termen im Zähler herausziehen:

$$A^{-1} = \frac{(-A^{-1}y + s)(-y^T A^{-1} + s^T)}{y^T (A^{-1}y - s)}$$

und Summanden vertauschen:

$$A^{-1} = \frac{(s - A^{-1}y)(s^T - y^T A^{-1})}{y^T (A^{-1}y - s)}$$

Aus dem rechten Term kann man aufgrund der Symmetrie das Transponieren herausziehen:

$$A^{-1} = \frac{(s - A^{-1}y)(s - A^{-1}y)^T}{y^T (A^{-1}y - s)}$$

Weiterhin kann man aus dem Nenner ebenfalls ein Minus entwerfen und die Summanden vertauschen:

$$A^{-1} + \frac{(s - A^{-1}y)(s - A^{-1}y)^T}{y^T(s - A^{-1}y)}$$

Da es sich beim Nenner ebenfalls um eine Zahl handelt (beispielhaft für ein 2×2 -System):

$$\begin{bmatrix} 1 & 2 \end{bmatrix} \left(\begin{bmatrix} 3 \\ 1 \end{bmatrix} - \begin{bmatrix} 1 & -2 \\ -2 & 3 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right)$$

kann man ihn auch so schreiben:

$$A^{-1} + \frac{(s - A^{-1}y)(s - A^{-1}y)^T}{(s - A^{-1}y)^T y}$$

Damit erhält man nun die Update-Formel für das Inverse-Verfahren:

$$B^{(k+1)} = B^k + \frac{(s^k - B^k y^k)(s^k - B^k y^k)^T}{(s^k - B^k y^k)^T y^k}$$

Aufgabe 6

Siehe GaussNewton.m.

Aufgabe 7

Die erste Funktion

$$f(t, x_1, x_2) = x_1 \cdot e^{x_2 \cdot t}$$

mit partiellen Ableitungen:

$$\frac{df}{dx_1} = e^{x_2 \cdot t}, \quad \frac{df}{dx_2} = t \cdot x_1 \cdot e^{x_2 \cdot t}$$

hat mit dem gegebenen Datensatz folgenden Residuen-Vektor:

$$r = \begin{bmatrix} f(0, x_1, x_2) - 2 \\ f(1, x_1, x_2) - 0.7 \\ f(2, x_1, x_2) - 0.3 \\ f(3, x_1, x_2) - 0.1 \end{bmatrix}$$

und diese Jacobi-Matrix (r'):

$$J = \begin{bmatrix} \frac{df}{dx_1}(0, x_1, x_2) & \frac{df}{dx_2}(0, x_1, x_2) \\ \frac{df}{dx_1}(1, x_1, x_2) & \frac{df}{dx_2}(1, x_1, x_2) \\ \frac{df}{dx_1}(2, x_1, x_2) & \frac{df}{dx_2}(2, x_1, x_2) \\ \frac{df}{dx_1}(3, x_1, x_2) & \frac{df}{dx_2}(3, x_1, x_2) \end{bmatrix}$$

Schritt	\mathbf{x}	$\sum_{i=1}^M (r_i)^2$
1	$[0.50, 1.00]^T$	113.07
2	$[0.39, 0.74]^T$	16.64
3	$[0.69, 0.14]^T$	2.99
4	$[1.54, -0.66]^T$	0.24
5	$[1.98, -0.99]^T$	$2.5 \cdot 10^{-3}$
\vdots	\vdots	\vdots
10	$[2.00, -1.0]^T$	$2.0 \cdot 10^{-3}$

Abbildung 9: Verlauf der aufsummierten quadratischen Residuen mit dem gegebenen Datensatz und GaussNewton.m bei Abbruchbedingung $\|\nabla f\| \leq 10^{-8}$

Für f erhält man somit die Werte $x_1 = 1.9950$ und $x_2 = -1.0095$ nach 10 Iterationen.

Weiterhin gilt für die zweite Funktion

$$g(t, x_1, x_2, x_3) = x_1 \cdot e^{-(x_2^2 + x_3^2) \cdot t} \cdot \frac{\sinh(x_3^2 \cdot t)}{x_3^2}$$

mit den partiellen Ableitungen

$$\frac{dg}{dx_1} = e^{-(x_2^2 + x_3^2) \cdot t} \cdot \frac{\sinh(x_3^2 \cdot t)}{x_3^2}$$

$$\frac{dg}{dx_2} = -2t \cdot x_2 x_1 \cdot e^{-(x_2^2 + x_3^2) \cdot t} \cdot \frac{\sinh(x_3^2 \cdot t)}{x_3^2}$$

$$\frac{dg}{dx_3} = \frac{2 \cdot x_1 \cdot e^{-(x_2^2 + x_3^2) \cdot t} \cdot (t \cdot x_3^2 \cdot \cosh(x_3^2 \cdot t) - (x_3^2 \cdot t + 1) \cdot \sinh(x_3^2 \cdot t))}{x_3^2}$$

und dem gegebenen Datensatz folgender Residuen-Vektor:

$$r = \begin{bmatrix} g(6, x_1, x_2, x_3) - 24.19 \\ g(12, x_1, x_2, x_3) - 35.34 \\ \vdots \\ g(180, x_1, x_2, x_3) - 55.21 \end{bmatrix}$$

und diese Jakobi-Matrix (r'):

$$J = \begin{bmatrix} \frac{dg}{dx_1}(6, x_1, x_2, x_3) & \frac{dg}{dx_2}(6, x_1, x_2, x_3) & \frac{dg}{dx_3}(6, x_1, x_2, x_3) \\ \frac{dg}{dx_1}(12, x_1, x_2, x_3) & \frac{dg}{dx_2}(12, x_1, x_2, x_3) & \frac{dg}{dx_3}(12, x_1, x_2, x_3) \\ \vdots & \vdots & \vdots \\ \frac{dg}{dx_1}(180, x_1, x_2, x_3) & \frac{dg}{dx_2}(180, x_1, x_2, x_3) & \frac{dg}{dx_3}(180, x_1, x_2, x_3) \end{bmatrix}$$

Schritt	\mathbf{x}	$\sum_{i=1}^M (r_i)^2$
1	$[10.0, 0.05, 0.10]^T$	$1.81 \cdot 10^6$
2	$[9.12, 0.05, 0.12]^T$	$8.58 \cdot 10^5$
3	$[8.34, 0.05, 0.13]^T$	$4.82 \cdot 10^5$

Abbildung 10: Verlauf der aufsummierten quadratischen Residuen mit dem gegebenen Datensatz und GaussNewton.m bei Abbruchbedingung $\|\nabla f\| \leq 10^{-8}$ und konstanter Schrittweite $\alpha = 0.125$

Für die zweite Funktion $g(t, x_1, x_2, x_3) = x_1 \cdot e^{-(x_2^2 + x_3^2) \cdot t} \cdot \frac{\sinh(x_3^2 \cdot t)}{x_3^2}$ erhält man mit dem gegebenen Datensatz und den Startwerten:

- $x_0 = [10, 0.05, 0.1]^T$
- $x_0 = [7, 0.125, 0.25]^T$
- $x_0 = [3, 0.1, 0.05]^T$

die Werte

- $x_1 = 3.5355, x_2 = 0.0546, x_3 = 0.1539$

nach 117, 247 bzw. 609 Iterationen. Abbruchkriterium war $\|J(x)^T \cdot r(x)\| \leq 10^{-8}$. Die Wolfe-Powell Schrittweitensteuerung hat bei dieser Funktion nicht zum Erfolg geführt da nach etwa 10 Durchläufen eine sehr kleine Schrittweite (im Bereich $\alpha = 10^{-8}$) angenommen wurde und das Verfahren daher nicht konvergiert ist. Wählt man dagegen händisch eine kleine Schrittweite (z.B. $\alpha = 0.1$ oder je nach Startwert $\alpha = 0.05$) konvergiert das Verfahren wieder.

Allgemein reagiert die Funktion g sehr empfindlich auf kleine Änderungen in den Startwerten. Das liegt vermutlich an den stark unterschiedlichen Werten der einzelnen Faktoren ($x_1 \cdot e^{-(x_2^2 + x_3^2) \cdot t}$ ist sehr klein während $\frac{\sinh(x_3^2 \cdot t)}{x_3^2}$ sehr groß wird) aufgrundessen es zu numerischer Instabilität kommt (z.B. zeigt Matlab dann NaN).

Aufgabe 8




Abbildung 11: Modellfunktion und Datensatz für $f(t, x_1, x_2) = x_1 \cdot e^{x_2 \cdot t}$




Abbildung 12: Modellfunktion und Datensatz für $g(t, x_1, x_2, x_3) = x_1 \cdot e^{-(x_2^2 + x_3^2) \cdot t} \cdot \frac{\sinh(x_3^2 \cdot t)}{x_3^2}$

Aufgabe 9

Bei einem Least-Squares-Problem wird der Abstand von einer Funktion f zu den gegebenen Datenpunkten (t, y) minimiert, die Zielfunktion (nach Folien-satz) ist daher:

$$f_{\text{LeastSquares}}(x) = \sum_{i=1}^m (f(t_i, x_1, x_2, \dots, x_n) - y_i)^2$$

Es werden also alle Residuen:

$$r(x) = \begin{bmatrix} f(t_1, x_1, \dots, x_n) - y_1 \\ f(t_2, x_1, \dots, x_n) - y_2 \\ \vdots \end{bmatrix}$$

quadriert und aufsummiert. $f_{LeastSquares}(x)$ ist somit der erste Parameter, den InverseBFGS erhält.

Weiterhin ist die Jacobi-Matrix definiert als:

$$J = \begin{bmatrix} \frac{df}{dx_1}(t_1, x_1, \dots, x_n) & \frac{df}{dx_2}(t_1, x_1, \dots, x_n) & \dots \\ \frac{df}{dx_1}(t_2, x_1, \dots, x_n) & \frac{df}{dx_2}(t_2, x_1, \dots, x_n) & \dots \\ \vdots & \vdots & \vdots \end{bmatrix}$$

Nach Foliensatz ist der Gradient definiert als: $\nabla f(x) = 2 \cdot J(x)^T \cdot r(x)$. Dies ist der zweite Parameter, den das BFGS-Verfahren erhält, zusammen mit einem Startwert.

Für die erste Funktion $f(t, x_1, x_2) = x_1 \cdot e^{x_2 \cdot t}$ liefert das BFGS-Verfahren den korrekten Wert. Für die zweite Funktion liefert es jedoch z.B.

$[9.8962, 11.4152, 1.5202]^T$ da beim ersten Durchlauf der Wert des negativen Gradienten verwendet wird (da $B = I$) und dadurch die Norm des Gradienten auf 0 sinkt (Abbruchbedingung).